data_analysis

October 30, 2021

1 Analiza Danych w Pythonie: pandas

1.0.1 23 października 2021

1.0.2 pandas

Biblioteka pandas jest podstawowym narzędziem w ekosystemie Pythona do analizy danych: *dostarcza dwa podstawowe typy danych: Series (szereg, 1D) i DataFrame (ramka danych, 2D); *operacje na tych obiektach: obsługa brakujących wartości, łączenie danych; *obsługuje dane różnego typu, np. szeregi czasowe; * biblioteka bazuje na numpy – bibliotece do obliczeń numerycznych; * pozwala też na prostą wizualizację danych; * ETL: extract, transform, load.

Żeby zaimportowąc bibliotekę pandas wystarczy:

```
[]: import pandas as pd
```

Zadanie 0: sprawdź, czy masz zainstalowaną bibliotekę pandas.

1.0.3 Szereg (pd.Series)

Reprezentacja danych jednowymiarowych: * możemy stworzyć Series z listy lub słownika; * W przypadku słownika klucze stają się indeksem; * dane muszą być jednorodne, inaczej nastąpi automatyczna konwersja.

Najprościej jest stworzyć szereg z pythonowej listy lub słownika. Poniżej jest przykład przedstawiający tworzenie szeregu z danych, które są zawarte w liście:

```
[]: data = [211819, 682758, 737011, 779511, 673790, 673790, 444177, 136791]
s = pd.Series(data)
print(s)
```

- 0 211819
- 1 682758
- 2 737011
- 3 779511
- 4 673790
- 5 673790
- 6 444177

7 136791 dtype: int64

A tu ze słownika:

```
April
              211819
May
              682758
June
             737011
July
             779511
August
              673790
September
              673790
October
              444177
November
              136791
```

dtype: int64

Jak widzimy w przypadku słownika indeks szeregu został stworzony na podstawie kluczy w słowniku. W przypadku listy indeks jest generowany klucz automatyczny, tj. liczby od 0 do n.

Podczas tworzenia szeregu możemy zdefiniować indeks, jak i nazwę szeregu:

```
[]: months = ['April', 'May', 'June', 'July', 'August', 'September', 'October', □

→'November']

data = [211819, 682758, 737011, 779511, 673790, 673790, 444177, 136791]

s = pd.Series(data, months, int, 'Rides')

s = pd.Series(data, dtype=int, index=months, name='Rides')

s = pd.Series(data=data, dtype=int, index=months, name='Rides')

s
```

```
[]: April
                  211819
    May
                  682758
     June
                  737011
     July
                  779511
     August
                  673790
     September
                  673790
     October
                  444177
     November
                  136791
    Name: Rides, dtype: int64
```

Podstawowa cechą szeregu jest wykonywanie operacji w sposób wektorowy. Działa to w następujący

sposób: * gdy w obu szeregach jest zawarty ten sam klucz, to są sumowane ich wartości; * w przeciwnym przypadku wartość klucza w wynikowym szeregu to pd.NaN.

[]: August 880599.0
July 973827.0
June 908505.0
May 830656.0
October NaN
September 814282.0
dtype: float64

Możemy wykonać operacje arytmetyczne na szeregu:

```
[]: members = pd.Series({'May': 682758, 'June': 737011, 'July': 779511, 'August': G673790, 'September': 673790, 'October': 444177})

members += 1000

members
```

[]: May 683758
June 738011
July 780511
August 674790
September 674790
October 445177
dtype: int64

Tworzenie pd.Series (documentacja) Parametry: * data * index * dtype * name

1.0.4 Ramka danych (pd.DataFrame)

Reprezentacja danych tabelarycznych: * różnorodność tworzenia DataFrame; * poszczególne kolumny to pd.Series;

Ramka danych reprezentuje dane tabularyczne (2D), gdzie kolumny odpowiadają cechom, zaś wiersze kolejnym obserwacją (przykładami).

Ramkę danych możemy stworzyć na wiele sposobów, w zależności od tego w jaki sposób mamy zorganizowane dane: * możemy podać zagnieżdżony słownik (tj. słownik w słowniku) - wtedy klucze w głównym słowniku będą odpowiadać nazwom kolumn, a klucze w podsłownikach - nazwom kluczy.

```
[]: members = {'May': 682758, 'June': 737011, 'July': 779511, 'August':⊔

→673790, 'September': 673790, 'October': 444177}

occasionals = {'May': 147898, 'June': 171494, 'July': 194316, 'August': 206809,⊔

→'September': 140492, 'October': 53596}

df = pd.DataFrame({'members': members, 'occasionals': occasionals})

df
```

```
[]:
                members occasionals
                  682758
                                147898
     May
     June
                  737011
                                171494
     July
                  779511
                                194316
     August
                  673790
                                206809
     September
                  673790
                                140492
     October
                  444177
                                 53596
```

Drugim popularnym sposobem jest przekazanie listy słowników. Wtedy pandas zinterpretuje to jako listę przykładów:

```
[]: members occasionals
0 682758 147898
1 737011 171494
2 779511 194316
```

Możemy też wykorzystać metodę from_dict:

```
[]: data = {
    'May': {'members': 682758, 'occasionals': 147898},
    'June': {'members': 737011, 'occasionals': 171494},
```

```
'July': {'members': 779511, 'occasionals': 194316}
}

df = pd.DataFrame.from_dict(data, orient='index')
df = pd.DataFrame.from_dict(data, orient='columns')
# df = pd.DataFrame(data)

df
```

[]: May June July members 682758 737011 779511 occasionals 147898 171494 194316

1.0.5 Wczytywanie danych

Biblioteka pandas pozwala na wczytanie danych z różnych formatów i źródeł: * formaty tekstowe: csv, tsv, json, HTML... * pliki arkuszy kalkulacyjnych: Excel * bazy danych: sql * inne: sas spss Pliki nie muszą znajdować się dysku, możemy np. podać link.

Dane są wczytywane bezpośrednio do pd. DataFrame.

```
[]: # df = pd.read_csv('gapminder.csv')

df = pd.read_excel('./bikes.xlsx', engine='openpyxl')
df
```

```
[]:
                 start date
                             start station code
                                                            end date \
     0 2019-04-14 07:55:22
                                            6001 2019-04-14 08:07:16
     1 2019-04-14 07:59:31
                                            6411 2019-04-14 08:09:18
     2 2019-04-14 07:59:55
                                            6097 2019-04-14 08:12:11
     3 2019-04-14 07:59:57
                                            6310 2019-04-14 08:27:58
     4 2019-04-14 08:00:37
                                            7029 2019-04-14 08:14:12
     95 2019-04-14 08:25:52
                                            7043 2019-04-14 08:30:20
                                            6229 2019-04-14 08:30:49
     96 2019-04-14 08:26:04
     97 2019-04-14 08:26:44
                                            6158 2019-04-14 08:48:29
     98 2019-04-14 08:27:13
                                            7043 2019-04-14 08:32:09
     99 2019-04-14 08:27:18
                                            6155 2019-04-14 08:44:13
         end station code duration sec
                                         is member
     0
                     6132
                                    713
                                                  1
     1
                     6411
                                     587
                                                  1
     2
                     6036
                                    736
                                                  1
     3
                     6345
                                    1680
                                                  1
     4
                     6250
                                    814
                                                  0
     95
                     6387
                                                  1
                                     267
```

```
96
                   6212
                                     285
                                                     1
97
                   6277
                                                     1
                                    1304
98
                   6387
                                     296
                                                     1
                   6075
99
                                    1015
                                                     1
```

[100 rows x 6 columns]

```
[]: import sqlite3
with sqlite3.connect('astro-timeline.sqlite3') as db:
    df = pd.read_sql("select * from logs", db)
[]: import sqlalchemy
```

```
[]: import sqlalchemy
engine = sqlalchemy.create_engine('sqlite:///astro-timeline.sqlite3', echo=True)
connection = engine.raw_connection()

df = pd.read_sql_query('select * from logs', con=connection)

df
```

```
[]:
         id
                              datetime
                                          level \
     0
          1
            1969-07-14 21:00:00+00:00
                                           INFO
     1
           1969-07-16 13:31:53+00:00
                                        WARNING
     2
          3 1969-07-16 13:33:23+00:00
                                          DEBUG
     3
          4 1969-07-16 13:34:44+00:00
                                        WARNING
           1969-07-16 13:35:17+00:00
                                          DEBUG
     5
          6 1969-07-16 13:39:40+00:00
                                          DEBUG
         7 1969-07-16 16:22:13+00:00
                                           INFO
     6
     7
         8 1969-07-16 16:56:03+00:00
                                           INFO
     8
         9 1969-07-16 17:21:50+00:00
                                           INFO
     9
         10 1969-07-16 21:43:36+00:00
                                           INFO
         11 1969-07-20 17:44:00+00:00
     10
                                           INFO
         12 1969-07-20 20:05:05+00:00
                                        WARNING
     11
     12
         13 1969-07-20 20:10:22+00:00
                                          ERROR
     13
         14 1969-07-20 20:14:18+00:00
                                          ERROR
         15 1969-07-20 20:17:39+00:00
                                        WARNING
     14
     15
         16 1969-07-21 02:39:33+00:00
                                          DEBUG
        17 1969-07-21 02:56:15+00:00
     16
                                        WARNING
     17
         18 1969-07-21 02:56:15+00:00
                                        WARNING
         19 1969-07-21 03:05:58+00:00
                                          DEBUG
     18
     19
         20 1969-07-21 03:15:16+00:00
                                           INFO
     20
         21 1969-07-21 05:11:13+00:00
                                          DEBUG
     21
        22 1969-07-21 17:54:00+00:00
                                        WARNING
        23 1969-07-21 21:35:00+00:00
     22
                                           INFO
    23
         24 1969-07-22 04:55:42+00:00
                                        WARNING
         25 1969-07-24 16:21:12+00:00
     24
                                           INFO
```

```
26
         27
            1969-07-24 16:50:35+00:00
                                        WARNING
    27
         28
            1969-07-24 17:29:00+00:00
                                           INFO
                                                   message
    0
                                Terminal countdown started
    1
                                 S-IC engine ignition (#5)
    2
                 Maximum dynamic pressure (735.17 lb/ft^2)
    3
                                             S-II ignition
    4
                            Launch escape tower jettisoned
    5
                                 S-II center engine cutoff
    6
                                      Translunar injection
    7
                                  CSM docked with LM/S-IVB
    8
                            Lunar orbit insertion ignition
    9
                      Lunar orbit circularization ignition
    10
                                           CSM/LM undocked
    11
                        LM powered descent engine ignition
    12
                                             LM 1202 alarm
    13
                                              LM 1201 alarm
    14
                                          LM lunar landing
    15
                                  EVA started (hatch open)
    16
                        1st step taken lunar surface (CDR)
    17
         That's one small step for [a] man... one giant...
    18
               Contingency sample collection started (CDR)
    19
                                      LMP on lunar surface
    20
                                  EVA ended (hatch closed)
                        LM lunar liftoff ignition (LM APS)
    21
    22
                                              CSM/LM docked
    23
                       Transearth injection ignition (SPS)
    24
                                          CM/SM separation
    25
                                                      Entry
    26
                            Splashdown (went to apex-down)
    27
                                                Crew egress
[]: url = 'https://raw.githubusercontent.com/tomekd/Python2021/main/homework01/
     df = pd.read csv(url)
    df
[]:
                   Unnamed: 0
                                                          gdp
                                                               population \
                               female_BMI male_BMI
                                                               26528741.0
    0
                  Afghanistan
                                 21.07402
                                           20.62058
                                                       1311.0
    1
                      Albania
                                 25.65726
                                           26.44657
                                                       8644.0
                                                                2968026.0
    2
                      Algeria
                                 26.36841
                                           24.59620
                                                      12314.0
                                                              34811059.0
    3
                                           22.25083
                                                       7103.0
                                                               19842251.0
                       Angola
                                 23.48431
                                           25.76602
                                                      25736.0
     4
          Antigua and Barbuda
                                 27.50545
                                                                  85350.0
```

WARNING

25

26

1969-07-24 16:35:05+00:00

```
170
                     Venezuela
                                   28.13408
                                             27.44500
                                                        17911.0 28116716.0
     171
                                   21.06500
                                             20.91630
                                                         4085.0 86589342.0
                       Vietnam
     172
                     Palestine
                                   29.02643
                                             26.57750
                                                         3564.0
                                                                   3854667.0
     173
                                                         3039.0 13114579.0
                        Zambia
                                   23.05436
                                             20.68321
     174
                      Zimbabwe
                                   24.64522
                                             22.02660
                                                         1286.0 13495462.0
          under5mortality life_expectancy fertility
                     110.4
                                        52.8
     0
                                                    6.20
                                                    1.76
     1
                      17.9
                                        76.8
     2
                      29.5
                                        75.5
                                                    2.73
     3
                     192.0
                                        56.7
                                                    6.43
     4
                      10.9
                                        75.5
                                                    2.16
                       •••
     . .
     170
                      17.1
                                        74.2
                                                    2.53
                      26.2
                                        74.1
                                                    1.86
     171
     172
                                        74.1
                                                    4.38
                      24.7
     173
                      94.9
                                        51.1
                                                    5.88
     174
                      98.3
                                        47.3
                                                    3.85
     [175 rows x 8 columns]
[]: df = pd.read_csv('./titanic_train.tsv', sep='\t')
     df
[]:
          PassengerId
                        Survived
                                  Pclass
                                        3
     0
                     1
                               0
                     2
                               1
     1
                                        1
     2
                     3
                               1
                                        3
     3
                     4
                               1
                                        1
     4
                     5
                               0
                                        3
     . .
                                        2
     886
                  887
                               0
                                        1
     887
                  888
                               1
     888
                  889
                               0
                                        3
     889
                  890
                               1
                                        1
     890
                  891
                               0
                                        3
                                                                               SibSp
                                                          Name
                                                                    Sex
                                                                          Age
     0
                                     Braund\t Mr. Owen Harris
                                                                         22.0
                                                                   male
                                                                                    1
     1
          Cumings\t Mrs. John Bradley (Florence Briggs T... female 38.0
                                                                                  1
     2
                                      Heikkinen\t Miss. Laina
                                                                female
                                                                         26.0
                                                                                    0
     3
              Futrelle\t Mrs. Jacques Heath (Lily May Peel)
                                                                female
                                                                         35.0
                                                                                    1
     4
                                    Allen\t Mr. William Henry
                                                                   male
                                                                         35.0
                                       Montvila\t Rev. Juozas
                                                                         27.0
                                                                                    0
     886
                                                                  male
     887
                               Graham\t Miss. Margaret Edith
                                                                         19.0
                                                                                    0
                                                                female
```

female

NaN

1

Johnston\t Miss. Catherine Helen "Carrie"

888

```
889
                                      Behr\t Mr. Karl Howell
                                                                 male
                                                                       26.0
                                                                                  0
     890
                                                                       32.0
                                                                                  0
                                        Dooley\t Mr. Patrick
                                                                 male
          Parch
                                       Fare Cabin Embarked
                            Ticket
     0
              0
                        A/5 21171
                                     7.2500
                                              NaN
                                                          S
              0
                         PC 17599
                                    71.2833
                                              C85
                                                          С
     1
     2
              0
                 STON/02. 3101282
                                     7.9250
                                              NaN
                                                          S
     3
              0
                                                          S
                            113803
                                    53.1000 C123
     4
              0
                            373450
                                     8.0500
                                                          S
                                              NaN
     . .
                                        •••
                                               •••
     886
              0
                                                          S
                            211536
                                    13.0000
                                              NaN
     887
              0
                            112053
                                    30.0000
                                              B42
                                                          S
     888
              2
                       W./C. 6607
                                    23.4500
                                              NaN
                                                          S
                                                          С
     889
              0
                            111369
                                    30.0000
                                             C148
     890
              0
                            370376
                                     7.7500
                                                          Q
                                              NaN
     [891 rows x 12 columns]
[]: df = pd.read_csv('gapminder.csv', index_col='Country')
     df
[]:
                           female_BMI
                                       male BMI
                                                           population \
                                                      gdp
     Country
                             21.07402
                                       20.62058
                                                   1311.0 26528741.0
     Afghanistan
                                                            2968026.0
     Albania
                             25.65726
                                       26.44657
                                                  8644.0
     Algeria
                             26.36841
                                       24.59620
                                                 12314.0
                                                           34811059.0
                             23.48431
                                       22.25083
                                                           19842251.0
     Angola
                                                   7103.0
     Antigua and Barbuda
                             27.50545
                                       25.76602
                                                 25736.0
                                                              85350.0
     Venezuela
                                       27.44500 17911.0 28116716.0
                             28.13408
     Vietnam
                             21.06500
                                       20.91630
                                                  4085.0 86589342.0
     Palestine
                             29.02643
                                       26.57750
                                                   3564.0
                                                            3854667.0
     Zambia
                             23.05436
                                       20.68321
                                                   3039.0
                                                           13114579.0
     Zimbabwe
                             24.64522
                                       22.02660
                                                   1286.0
                                                          13495462.0
                           under5mortality life_expectancy fertility
     Country
     Afghanistan
                                     110.4
                                                        52.8
                                                                   6.20
     Albania
                                      17.9
                                                        76.8
                                                                   1.76
     Algeria
                                      29.5
                                                        75.5
                                                                   2.73
     Angola
                                     192.0
                                                        56.7
                                                                   6.43
     Antigua and Barbuda
                                      10.9
                                                        75.5
                                                                   2.16
     Venezuela
                                      17.1
                                                        74.2
                                                                   2.53
                                      26.2
                                                        74.1
                                                                   1.86
     Vietnam
     Palestine
                                      24.7
                                                        74.1
                                                                   4.38
     Zambia
```

51.1

5.88

94.9

Zimbabwe 98.3 47.3 3.85

[175 rows x 7 columns]

```
[]:
                              gdp population
    Country
    Afghanistan
                          1311.0 26528741.0
    Albania
                           8644.0
                                   2968026.0
    Algeria
                          12314.0 34811059.0
                          7103.0 19842251.0
    Angola
    Antigua and Barbuda 25736.0
                                     85350.0
    Venezuela
                          17911.0 28116716.0
    Vietnam
                           4085.0 86589342.0
    Palestine
                           3564.0
                                  3854667.0
    Zambia
                          3039.0 13114579.0
    Zimbabwe
                          1286.0 13495462.0
```

[175 rows x 2 columns]

Wczytywanie danych

- pandas pozwala na wczytanie danych z najróżniejszych źródeł (lista);
- każda funkcja ma listę argumentów, które pozwalają na ustawić parametry (np. read_csv).

1.0.6 Zapis i eksport danych

```
[]: df.to_excel('tmp.xlsx')
```

```
[]: df.to_json()
[]: '{"members":{"May":682758,"June":737011,"July":779511,"August":673790,"September
     ":673790, "October":444177}, "occasionals":{"May":147898, "June":171494, "July":1943
     16, "August": 206809, "September": 140492, "October": 53596}}'
[]: data = df.to dict()
     data
[]: {'members': {'May': 682758,
       'June': 737011,
       'July': 779511,
       'August': 673790,
       'September': 673790,
       'October': 444177},
      'occasionals': {'May': 147898,
       'June': 171494,
       'July': 194316,
       'August': 206809,
       'September': 140492,
       'October': 53596}}
[]: df.to_clipboard()
    Podstawowe metody pd.Series i pd.DataFrame
[]: members = pd.Series({'May': 682758, 'June': 737011, 'July': 779511, 'August':
     →673790,
     'September': 673790, 'October': 444177})
     occasionals = pd.Series({'May': 147898, 'June': 171494, 'July': 194316, __
     'September': 140492, 'October': 53596})
     df = pd.DataFrame({'members': members, 'occasionals': occasionals})
     df
[]:
                members occasionals
    May
                 682758
                              147898
     June
                737011
                              171494
     July
                779511
                              194316
    August
                              206809
                673790
     September
                 673790
                              140492
     October
                 444177
                               53596
```

Metoda head pozwala tworzy nową ramkę danych z pierwszymi 5 przykładami:

[]: df.head()

[]: members occasionals May 682758 147898

Metoda tail robi to samo, ale z 5 ostatnymi przykładami:

```
[]: df.tail()
```

[]: members occasionals June 737011 171494 July 779511 194316 August 673790 206809 September 673790 140492 October 444177 53596

Metoda sample pozwala na stworzenie nowej ramki danych z wylosowanymi n przykładami:

[]: df.sample(3)

[]: members occasionals

May 682758 147898

August 673790 206809

September 673790 140492

Metoda describe zwraca podstawowe statystyki m.in.: liczebność, średnią, wartości skrajne:

[]: df.describe()

[]: members occasionals count 6.000000 6.000000 665172.833333 152434.166667 mean std 116216.045456 54783.506738 min 444177.000000 53596.000000 142343.500000 25% 673790.000000 50% 678274.000000 159696.000000 75% 723447.750000 188610.500000 779511.000000 206809.000000 max

Metoda info zwraca informacje techniczne o kolumnach: np. typ danych:

[]: df.info()

0 members 6 non-null int64

```
dtypes: int64(2)
    memory usage: 144.0+ bytes
    Atrybut columns zwraca nazwy kolumn w ramce danych:
[]: list(df.columns)
[]: ['members', 'occasionals']
    Natomiast atrybut index zwraca indeks:
[]: df.index
[]: Index(['May', 'June', 'July', 'August', 'September', 'October'], dtype='object')
    Podstawową informacją o ramce danych to liczba przykładów w ramce danych. Możemy wykorzys-
    tać to tego funkcję len:
[]: len(df)
[]:6
    Natomiast atrybut shape zwraca nam krotkę z liczbą przykładów i liczbą kolumn:
[]: df.shape
[]: (6, 2)
    Operacja arytmetyczne
       • max
       • min
       mean
       • count
[]: df = pd.read_csv('./gapminder.csv', index_col='Country', nrows=5)
[]: df.std()
[]: female_BMI
                         2.555711e+00
    {\tt male\_BMI}
                         2.445384e+00
     gdp
                         9.130827e+03
                         1.499161e+07
    population
    under5mortality
                         7.800758e+01
     life_expectancy
                         1.169628e+01
     fertility
                         2.272516e+00
```

int64

occasionals 6 non-null

dtype: float64

1.0.7 Indeksowanie

```
[]: df = pd.read_csv('./gapminder.csv', index_col='Country', nrows=5)
df
```

[]:	female_BMI	male_BMI	gdp	population \
Country				
Afghanistan	21.07402	20.62058	1311.0	26528741.0
Albania	25.65726	26.44657	8644.0	2968026.0
Algeria	26.36841	24.59620	12314.0	34811059.0
Angola	23.48431	22.25083	7103.0	19842251.0
Antigua and Barbuda	27.50545	25.76602	25736.0	85350.0
	under5morta	ality life	_expectan	cy fertility
Country				
Afghanistan	1	10.4	52	.8 6.20
Albania		17.9	76	.8 1.76
Algeria		29.5	75	.5 2.73
Angola	1	92.0	56	.7 6.43
Antigua and Barbuda		10.9	75	.5 2.16

Kolumny

[]: # df.gdp

df['gdp']

[]: Country

Afghanistan 1311.0
Albania 8644.0
Algeria 12314.0
Angola 7103.0
Antigua and Barbuda 25736.0
Name: gdp, dtype: float64

```
[]: cols = ['gdp', 'population']

df[cols]
```

[]: gdp population
Country
Afghanistan 1311.0 26528741.0
Albania 8644.0 2968026.0
Algeria 12314.0 34811059.0
Angola 7103.0 19842251.0
Antigua and Barbuda 25736.0 85350.0

DataFrame.loc[]

- pozwala na odwołanie się do wiersza;
- opcjonalnie możemy podać też nazwę kolumny;
- umożliwia slicing, czyli odwoływanie się po zakresie.

```
[]:  # print(df)
     df.loc['Angola']
[]: female_BMI
                        2.348431e+01
    {\tt male\_BMI}
                        2.225083e+01
     gdp
                        7.103000e+03
    population
                        1.984225e+07
    under5mortality
                        1.920000e+02
    life_expectancy
                        5.670000e+01
     fertility
                        6.430000e+00
    Name: Angola, dtype: float64
[]: df.loc[['Albania', 'Angola']]
[]:
              female_BMI male_BMI
                                       gdp
                                            population under5mortality \
     Country
     Albania
                25.65726
                          26.44657
                                    8644.0
                                             2968026.0
                                                                    17.9
                23.48431
                          22.25083
                                    7103.0 19842251.0
                                                                   192.0
     Angola
              life_expectancy fertility
     Country
                         76.8
     Albania
                                    1.76
                         56.7
     Angola
                                    6.43
[]: df2 = df.loc[['Albania', 'Angola'], ['gdp', 'population']]
     df2
[]:
                 gdp population
     Country
     Albania 8644.0
                       2968026.0
     Angola
              7103.0 19842251.0
[]: df.loc['Albania': 'Angola', 'gdp': 'life_expectancy']
[]:
                  gdp population under5mortality life_expectancy
     Country
                                                                76.8
     Albania
               8644.0
                        2968026.0
                                              17.9
     Algeria
              12314.0
                       34811059.0
                                              29.5
                                                                75.5
     Angola
                                                                56.7
               7103.0
                       19842251.0
                                             192.0
```

1.0.8 Metoda pd.DataFrame.at

Antigua and Barbuda

Pozwala na uzyskanie wartości pojedyńczej komórki.

```
[]: df.at['Angola', 'gdp']
```

[]: 7103.0

1.0.9 Dodawanie i modyfikowanie danych

```
[]: df = pd.read_csv('./gapminder.csv', index_col='Country', nrows=5)
df
```

```
[]:
                         female_BMI male_BMI
                                                   gdp
                                                        population \
    Country
    Afghanistan
                           21.07402
                                     20.62058
                                                1311.0
                                                        26528741.0
    Albania
                           25.65726 26.44657
                                                8644.0
                                                         2968026.0
                           26.36841 24.59620 12314.0 34811059.0
    Algeria
    Angola
                           23.48431 22.25083
                                                7103.0
                                                        19842251.0
    Antigua and Barbuda
                           27.50545 25.76602 25736.0
                                                           85350.0
                         under5mortality life_expectancy fertility
    Country
                                                                6.20
    Afghanistan
                                   110.4
                                                     52.8
    Albania
                                    17.9
                                                     76.8
                                                                1.76
                                    29.5
                                                     75.5
                                                                2.73
    Algeria
                                                     56.7
    Angola
                                   192.0
                                                                6.43
```

75.5

2.16

10.9

```
[]:
                         female_BMI
                                    male_BMI
                                                  gdp population \
    Country
    Afghanistan
                           21.07402
                                    20.62058
                                               1311.0 26528741.0
    Albania
                           25.65726
                                    26.44657
                                               8644.0
                                                        2968026.0
    Algeria
                           26.36841 24.59620 12314.0 34811059.0
    Angola
                           23.48431 22.25083
                                               7103.0 19842251.0
    Antigua and Barbuda
                           27.50545 25.76602 25736.0
                                                          85350.0
```

```
under5mortality life_expectancy fertility continent \
     Country
     Afghanistan
                                    110.4
                                                      52.8
                                                                  6.20
                                                                            Asia
                                     17.9
                                                      76.8
                                                                  1.76
     Albania
                                                                          Europe
     Algeria
                                     29.5
                                                      75.5
                                                                  2.73
                                                                          Africa
                                    192.0
                                                                  6.43
     Angola
                                                      56.7
                                                                          Africa
     Antigua and Barbuda
                                     10.9
                                                      75.5
                                                                  2.16 Americas
                          tmp
     Country
     Afghanistan
                            1
     Albania
                            1
     Algeria
                            1
     Angola
                            1
     Antigua and Barbuda
[]: df.loc['Argentina'] = {
         'female_BMI': 27.46523,
         'male_BMI': 27.5017,
         'gdp': 14646.0,
         'population': 40381860.0,
         'under5mortality': 15.4,
         'life_expectancy': 75.4,
         'fertility': 2.24
     }
     df
[]:
                          female_BMI
                                      {\tt male\_BMI}
                                                    gdp population \
     Country
     Afghanistan
                            21.07402
                                      20.62058
                                                 1311.0 26528741.0
     Albania
                            25.65726 26.44657
                                                 8644.0
                                                          2968026.0
                            26.36841 24.59620 12314.0 34811059.0
     Algeria
     Angola
                            23.48431 22.25083
                                                 7103.0
                                                         19842251.0
     Antigua and Barbuda
                            27.50545
                                      25.76602
                                                25736.0
                                                            85350.0
     Argentina
                            27.46523 27.50170 14646.0 40381860.0
                          under5mortality life_expectancy fertility continent \
     Country
     Afghanistan
                                    110.4
                                                      52.8
                                                                  6.20
                                                                            Asia
     Albania
                                     17.9
                                                      76.8
                                                                  1.76
                                                                          Europe
     Algeria
                                     29.5
                                                      75.5
                                                                  2.73
                                                                          Africa
                                    192.0
                                                      56.7
                                                                  6.43
                                                                          Africa
     Angola
                                     10.9
                                                      75.5
                                                                  2.16
     Antigua and Barbuda
                                                                        Americas
     Argentina
                                     15.4
                                                      75.4
                                                                  2.24
                                                                             NaN
                          tmp
```

Country

```
Afghanistan 1.0
Albania 1.0
Algeria 1.0
Angola 1.0
Antigua and Barbuda 1.0
Argentina NaN
```

```
[]: df.drop('gdp', axis='columns')
```

[]:		$female_BMI$	${\tt male_BMI}$	population	under5mortality	\
	Country					
	Afghanistan	21.07402	20.62058	26528741.0	110.4	
	Algeria	26.36841	24.59620	34811059.0	29.5	
	Antigua and Barbuda	27.50545	25.76602	85350.0	10.9	
	Argentina	27.46523	27.50170	40381860.0	15.4	

life_expectancy fertility continent tmp

Country

Afghanistan	52.8	6.20	Asia	1.0
Algeria	75.5	2.73	Africa	1.0
Antigua and Barbuda	75.5	2.16	Americas	1.0
Argentina	75.4	2.24	NaN	NaN

1.0.10 Filtrowanie

Są dwa podstawowe sposoby na filtrowanie danych w pd.DataFrame: * operator [] – najbardziej rozpowszechniony; * metoda query().

```
[]: df = pd.read_csv('./titanic_train.tsv', sep='\t', index_col='PassengerId')

df.head()
```

```
[]:
                   Survived Pclass \
     PassengerId
                          0
                                   3
     1
     2
                          1
                                   1
     3
                          1
                                   3
     4
                          1
                                   1
     5
                          0
                                   3
```

	Name Sex Age \setminus
PassengerId	
1	Braund\t Mr. Owen Harris male 22.0
2	Cumings\t Mrs. John Bradley (Florence Briggs T female 38.0
3	Heikkinen\t Miss. Laina female 26.0
4	Futrelle\t Mrs. Jacques Heath (Lily May Peel) female 35.0
5	Allen\t Mr. William Henry male 35.0

```
SibSp Parch
                                            Ticket
                                                       Fare Cabin Embarked
     PassengerId
                                                     7.2500
     1
                       1
                              0
                                        A/5 21171
                                                               NaN
                                                                          S
     2
                       1
                              0
                                          PC 17599
                                                   71.2833
                                                               C85
                                                                          C
     3
                                                                          S
                       0
                              0
                                 STON/02. 3101282
                                                     7.9250
                                                               NaN
     4
                              0
                                                    53.1000
                                                              C123
                                                                          S
                       1
                                            113803
     5
                       0
                              0
                                                                          S
                                            373450
                                                     8.0500
                                                               NaN
[]: pierwsza_klasa = df['Pclass'] == 1
     kobiety = df['Sex'] == 'female'
     df[pierwsza_klasa & kobiety]
[]:
                  Survived Pclass \
    PassengerId
     2
                          1
                                   1
     4
                          1
                                   1
     12
                          1
                                   1
     32
                          1
     53
                          1
                                   1
     857
                          1
                                   1
     863
                          1
                                   1
     872
                          1
                                   1
     880
                          1
                                   1
     888
                                                                  Name
                                                                           Sex
                                                                                  Age \
     PassengerId
     2
                  Cumings\t Mrs. John Bradley (Florence Briggs T... female 38.0
     4
                       Futrelle\t Mrs. Jacques Heath (Lily May Peel)
                                                                        female
     12
                                            Bonnell\t Miss. Elizabeth
                                                                        female
                                                                                 58.0
     32
                     Spencer\t Mrs. William Augustus (Marie Eugenie)
                                                                        female
                                                                                  NaN
     53
                           Harper\t Mrs. Henry Sleeper (Myna Haxtun)
                                                                        female
                                                                                 49.0
                         Wick\t Mrs. George Dennick (Mary Hitchcock)
     857
                                                                        female 45.0
                  Swift\t Mrs. Frederick Joel (Margaret Welles B... female 48.0
     863
     872
                  Beckwith\t Mrs. Richard Leonard (Sallie Monypeny)
                                                                        female
                                                                                 47.0
     880
                     Potter\t Mrs. Thomas Jr (Lily Alexenia Wilson)
                                                                        female
                                                                                 56.0
     888
                                        Graham\t Miss. Margaret Edith
                                                                        female
                                                                                 19.0
                  SibSp Parch
                                   Ticket
                                                Fare Cabin Embarked
     PassengerId
                       1
                                 PC 17599
                                             71.2833
                                                        C85
                                                                   С
     2
                              0
     4
                                   113803
                                             53.1000
                                                                   S
                       1
                              0
                                                      C123
     12
                       0
                              0
                                   113783
                                             26.5500 C103
                                                                   S
```

32		1	0	PC 17569	146.5208	B78	С
53		1	0	PC 17572	76.7292	D33	C
•••	•••	•••					
857		1	1	36928	164.8667	NaN	S
863		0	0	17466	25.9292	D17	S
872		1	1	11751	52.5542	D35	S
880		0	1	11767	83.1583	C50	C
888		0	0	112053	30.0000	B42	S

[94 rows x 11 columns]

Operatory

- & koniukcja (i)
- | alternatywa (lub)
- ~ negacja (nie)
- () jeżeli mamy kilka warunków to warto je uporządkować w nawiasy

[]: df[df['SibSp'] > df['Parch']]

[]:		Survived	Pclass	\
	PassengerId			
	1	0	3	
	2	1	1	
	4	1	1	
	8	0	3	
	10	1	2	
	•••	•••	•••	
	861	0	3	
	862	0	2	
	864	0	3	
	867	1	2	
	875	1	2	

	Name	Sex	Age	\
PassengerId				
1	Braund\t Mr. Owen Harris	male	22.0	
2	Cumings\t Mrs. John Bradley (Florence Briggs T f	emale 3	8.0	
4	Futrelle\t Mrs. Jacques Heath (Lily May Peel)	female	35.0	
8	Palsson\t Master. Gosta Leonard	male	2.0	
10	Nasser\t Mrs. Nicholas (Adele Achem)	female	14.0	
•••				
861	Hansen\t Mr. Claus Peter	male	41.0	
862	Giles\t Mr. Frederick Edward	male	21.0	
864	Sage\t Miss. Dorothy Edith "Dolly"	female	NaN	
867	Duran y More\t Miss. Asuncion	female	27.0	
875	Abelson\t Mrs. Samuel (Hannah Wizosky)	female	28.0	

	SibSp	Parch	Ticket	Fare	${\tt Cabin}$	${\tt Embarked}$
PassengerId						
1	1	0	A/5 21171	7.2500	NaN	S
2	1	0	PC 17599	71.2833	C85	C
4	1	0	113803	53.1000	C123	S
8	3	1	349909	21.0750	NaN	S
10	1	0	237736	30.0708	NaN	C
					••	
861	2	0	350026	14.1083	${\tt NaN}$	S
862	1	0	28134	11.5000	${\tt NaN}$	S
864	8	2	CA. 2343	69.5500	${\tt NaN}$	S
867	1	0	SC/PARIS 2149	13.8583	NaN	C
875	1	0	P/PP 3381	24.0000	NaN	C

[192 rows x 11 columns]

pd.DataFrame.query()

```
[]: df.query('Pclass == 1').head()
```

[]:		Survived	Pclass	\
	PassengerId			
	2	1	1	
	4	1	1	
	7	0	1	
	12	1	1	
	24	1	1	

			Name	Sex	Age	\
PassengerId						
2	Cumings\t Mrs. Joh	n Bradley (Florence Briggs	T femal	.e 38	.0	
4	Futrelle\t Mrs	. Jacques Heath (Lily May	Peel) fem	ale :	35.0	
7		McCarthy\t Mr. Time	thy J m	ale	54.0	
12		Bonnell\t Miss. Eliz	abeth fem	ale	58.0	
24		Sloper\t Mr. William Tho	mpson m	ale :	28.0	

	SibSp	Parch	Ticket	Fare	Cabin	Embarked
PassengerId						
2	1	0	PC 17599	71.2833	C85	C
4	1	0	113803	53.1000	C123	S
7	0	0	17463	51.8625	E46	S
12	0	0	113783	26.5500	C103	S
24	0	0	113788	35.5000	A6	S

```
[]: df.query('(Pclass == 1) and (Sex == "female")').head()
```

```
[]:
                  Survived Pclass \
     PassengerId
     2
                          1
                                   1
     4
                          1
                                   1
     12
                          1
                                   1
     32
                          1
                                   1
     53
                          1
                                   1
                                                                  Name
                                                                            Sex
                                                                                  Age \
     PassengerId
     2
                  Cumings\t Mrs. John Bradley (Florence Briggs T... female
     4
                       Futrelle\t Mrs. Jacques Heath (Lily May Peel)
                                                                         female
     12
                                            Bonnell\t Miss. Elizabeth
                                                                         female
                                                                                 58.0
     32
                     Spencer\t Mrs. William Augustus (Marie Eugenie)
                                                                         female
                                                                                  NaN
     53
                           Harper\t Mrs. Henry Sleeper (Myna Haxtun)
                                                                         female
                                                                                49.0
                  SibSp Parch
                                   Ticket
                                                Fare Cabin Embarked
     PassengerId
     2
                       1
                                 PC 17599
                                             71.2833
                                                        C85
                                                                   С
     4
                                                                   S
                       1
                              0
                                    113803
                                             53.1000
                                                      C123
                                                                   S
     12
                       0
                              0
                                    113783
                                             26.5500
                                                       C103
     32
                       1
                                 PC 17569
                                            146.5208
                                                                   С
                              0
                                                        B78
     53
                       1
                                 PC 17572
                                             76.7292
                                                        D33
[]: df.query('SibSp > Parch')
[]:
                  Survived Pclass \
     PassengerId
                          0
                                  3
     1
     2
                          1
                                   1
     4
                          1
                                   1
     8
                          0
                                  3
     10
                                   2
                          1
     861
                          0
                                  3
                                   2
     862
                          0
     864
                          0
                                   3
                                  2
     867
                          1
                                  2
     875
                          1
                                                                  Name
                                                                            Sex
                                                                                  Age \
     PassengerId
     1
                                             Braund\t Mr. Owen Harris
                                                                           male
                                                                                 22.0
     2
                  Cumings\t Mrs. John Bradley (Florence Briggs T... female 38.0
     4
                       Futrelle\t Mrs. Jacques Heath (Lily May Peel)
                                                                         female
                                                                                 35.0
     8
                                      Palsson\t Master. Gosta Leonard
                                                                                  2.0
                                                                         female
                                Nasser\t Mrs. Nicholas (Adele Achem)
     10
                                                                                14.0
```

```
861
                                            Hansen\t Mr. Claus Peter
                                                                         male
                                                                               41.0
     862
                                        Giles\t Mr. Frederick Edward
                                                                         male
                                                                               21.0
                                  Sage\t Miss. Dorothy Edith "Dolly"
                                                                       female
     864
                                                                                NaN
     867
                                       Duran y More\t Miss. Asuncion
                                                                       female
                                                                               27.0
     875
                             Abelson\t Mrs. Samuel (Hannah Wizosky)
                                                                       female
                                                                               28.0
                                                   Fare Cabin Embarked
                  SibSp Parch
                                        Ticket
     PassengerId
     1
                      1
                             0
                                     A/5 21171
                                                 7.2500
                                                           NaN
                                                                      S
     2
                                                           C85
                                                                      С
                      1
                             0
                                      PC 17599
                                                71.2833
     4
                      1
                             0
                                        113803
                                                53.1000
                                                         C123
                                                                      S
                                                                      S
     8
                      3
                             1
                                        349909
                                                21.0750
                                                          NaN
                                                                      C
     10
                      1
                             0
                                        237736
                                                30.0708
                                                          NaN
                                               14.1083
                                                                      S
     861
                      2
                             0
                                        350026
                                                           NaN
                                                                      S
     862
                             0
                                                           NaN
                      1
                                         28134
                                               11.5000
     864
                      8
                             2
                                      CA. 2343
                                                69.5500
                                                           NaN
                                                                      S
                                                                      С
     867
                      1
                                SC/PARIS 2149
                                                13.8583
                             0
                                                           NaN
     875
                                                                      C
                                     P/PP 3381
                                                24.0000
                                                           NaN
     [192 rows x 11 columns]
[]: my_age = 31
     df.query('Age == @my_age').shape
[]: (17, 11)
    Wywołanie funkcji na wierszach/kolumnach
[]: df = pd.read_csv('./gapminder.csv', index_col='Country', nrows=5)
     df
                          female_BMI
[]:
                                       male_BMI
                                                     gdp
                                                          population \
     Country
     Afghanistan
                             21.07402
                                       20.62058
                                                  1311.0
                                                           26528741.0
                             25.65726
                                       26.44657
                                                  8644.0
                                                            2968026.0
     Albania
     Algeria
                            26.36841
                                       24.59620
                                                 12314.0
                                                          34811059.0
                            23.48431
     Angola
                                       22.25083
                                                  7103.0
                                                           19842251.0
     Antigua and Barbuda
                            27.50545
                                       25.76602
                                                 25736.0
                                                              85350.0
                          under5mortality life_expectancy fertility
     Country
     Afghanistan
                                     110.4
                                                       52.8
                                                                   6.20
     Albania
                                      17.9
                                                       76.8
                                                                   1.76
     Algeria
                                      29.5
                                                       75.5
                                                                   2.73
```

```
6.43
     Angola
                                     192.0
                                                        56.7
                                      10.9
                                                        75.5
                                                                    2.16
     Antigua and Barbuda
[]: def bmi_level(bmi):
         if bmi <= 18.5:</pre>
             level = 'underweight'
         elif bmi < 25:
             level = 'normal'
         elif bmi < 30:</pre>
             level = 'overweight'
         else:
             level = 'obese'
         return level
     s = df['male_BMI'].map(bmi_level)
     s
[]: Country
     Afghanistan
                                 normal
     Albania
                             overweight
     Algeria
                                 normal
     Angola
                                 normal
     Antigua and Barbuda
                             overweight
     Name: male_BMI, dtype: object
[]: def bmi_level(row_data):
         bmi = row_data['male_BMI']
         if bmi <= 18.5:</pre>
             return 'underweight'
         elif bmi < 25:
             return 'normal'
         elif bmi < 30:</pre>
             return 'overweight'
         return 'obese'
     df.apply(bmi_level, axis=1)
[]: Country
     Afghanistan
                                 normal
     Albania
                             overweight
     Algeria
                                 normal
```

Zbiór wartości

dtype: object

Antigua and Barbuda

Angola

normal

overweight

```
[]: dane = pd.Series([1, 3, 2, 3, 1, 1, 2, 3, 2, 3])
dane.unique()
```

[]: array([1, 3, 2])

Zliczanie wartości

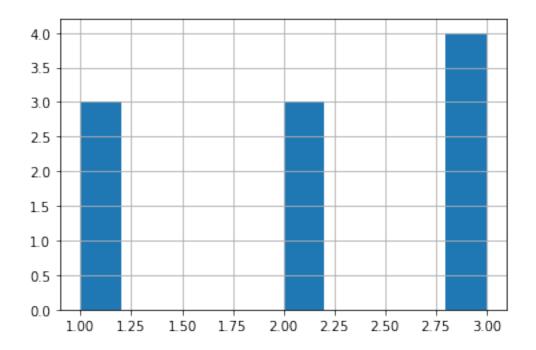
[]: dane = pd.Series([1, 3, 2, 3, 1, 1, 2, 3, 2, 3])

dane.value_counts()

[]: 3 4 1 3 2 3 dtype: int64

[]: dane.hist()

[]: <AxesSubplot:>



[]: df.transpose()

[]: Country Afghanistan Albania Algeria Angola \
female_BMI 2.107402e+01 2.565726e+01 2.636841e+01 2.348431e+01
male_BMI 2.062058e+01 2.644657e+01 2.459620e+01 2.225083e+01

```
gdp
                 1.311000e+03 8.644000e+03
                                            1.231400e+04 7.103000e+03
                               2.968026e+06
                                                           1.984225e+07
population
                 2.652874e+07
                                             3.481106e+07
under5mortality 1.104000e+02 1.790000e+01
                                             2.950000e+01
                                                           1.920000e+02
                                                           5.670000e+01
life_expectancy
                                             7.550000e+01
                 5.280000e+01
                               7.680000e+01
fertility
                 6.200000e+00 1.760000e+00
                                             2.730000e+00
                                                           6.430000e+00
Country
                 Antigua and Barbuda
female_BMI
                            27.50545
{\tt male\_BMI}
                            25.76602
gdp
                         25736.00000
population
                         85350.00000
under5mortality
                            10.90000
life_expectancy
                            75.50000
fertility
                             2.16000
```

1.0.11 Grupowanie (groupby)

Często zdarza się, gdy potrzebujemy podzielić dane ze względu na wartości w zadanej kolumnie, a następnie obliczenie zebranie danych w każdej z grup. Do tego służy metody groupby.

```
[]: df = pd.read_csv('./titanic_train.tsv', sep='\t', index_col='PassengerId')

df.head()
```

[]:		Survived	Pclass	\
	PassengerId			
	1	0	3	
	2	1	1	
	3	1	3	
	4	1	1	
	5	0	3	

					Name	Sex	Age	\	
PassengerId									
1			Braund	l\t Mr. Ow	en Harris	male	22.0		
2	Cumings\t Mrs. John Bradley (Florence Briggs T female 38.0								
3	_		Heikk	xinen\t Mi	lss. Laina	female	26.0		
4	Fu	trelle\	t Mrs. Jacques Hea	th (Lily	May Peel)	female	35.0		
5			Allen\t	Mr. Will	iam Henry	male	35.0		
					-				
	SibSp	Parch	Ticket	Fare	Cabin Emba	rked			
PassengerId									
1	1	0	A/5 21171	7.2500	NaN	S			
2	1	0	PC 17599	71.2833	C85	С			
3	0	0	STON/02. 3101282	7.9250	NaN	S			
4	1	0	113803	53.1000	C123	S			
5	0	0	373450	8.0500	NaN	S			

Przykład: chcemy obliczyć średnią dla każdej z kolumn z podziałem na płeć pasażera, która jest zawarta w kolumnie Sex. Stąd jako parametr do metody groupby podajemy nazwę kolumny Sex, a następnie wywołujemy metodę mean:

```
[]: df.groupby('Sex').mean()
```

```
[]:
             Survived
                           Pclass
                                          Age
                                                   SibSp
                                                             Parch
                                                                          Fare
     Sex
     female
             0.742038
                        2.159236
                                   27.915709
                                               0.694268
                                                          0.649682
                                                                     44.479818
     male
              0.188908
                        2.389948
                                   30.726645
                                               0.429809
                                                          0.235702
                                                                     25.523893
```

Możemy też podać listę nazw kolumn. Wtedy wartości zostaną obliczone dla każdej z wytworzonych grup:

```
[]: df.groupby(['Sex', 'Pclass']).mean()
```

[]:			Survived	Age	SibSp	Parch	Fare
	Sex	Pclass					
	${\tt female}$	1	0.968085	34.611765	0.553191	0.457447	106.125798
		2	0.921053	28.722973	0.486842	0.605263	21.970121
		3	0.500000	21.750000	0.895833	0.798611	16.118810
	male	1	0.368852	41.281386	0.311475	0.278689	67.226127
		2	0.157407	30.740707	0.342593	0.22222	19.741782
		3	0.135447	26.507589	0.498559	0.224784	12.661633

1.0.12 Pivot

Metoda pivot pozwala na stworzenie nowej ramki danych, gdzie indeks i nazwy kolumn są wartościami początkowej ranki danych.

Przykład: zobaczmy na poniższą ramkę danych, która zawiera informacje o jakości tłumaczenia dla pary językowej hausa-angielski. Kolumna system zawiera nazwę systemu, kolumna metric - nazwę metryki, zaś kolumna score- wartość metryki. Chcemy przedstawić te dane w następujący sposób: jako klucz chcemy mieć nazwę systemu, zaś jako kolumny - metryki. Możemy wykorzystać do tego metodę pivot, gdzie musimy podać 3 argumenty: * index: nazwę kolumny, na podstawie której zostanie stworzony indeks; * columns: nazwa kolumny, które zawiera nazwy kolumn dla nowej ramki danych; * values: nazwa kolumny, która zawiera interesujące nas dane.

```
[]:
                       system
                                      is_constrained
          pair
                                 id
                                                          metric
                                                                       score
     0
         ha-en
                    NiuTrans
                                382
                                                 True
                                                        bleu-all
                                                                  16.512243
     1
         ha-en
                    NiuTrans
                                382
                                                 True
                                                        chrf-all
                                                                    0.447248
     2
                                382
                                                 True
         ha-en
                    NiuTrans
                                                          bleu-A
                                                                  16.512243
     3
         ha-en
                    NiuTrans
                                382
                                                 True
                                                          chrf-A
                                                                    0.447248
     4
         ha-en
                    Online-B
                               1356
                                                False
                                                       bleu-all
                                                                   18.655658
     5
                    Online-B
                                                False
                                                        chrf-all
         ha-en
                               1356
                                                                    0.466582
```

6	ha-en	Online-B	1356	False	bleu-A	18.655658
7	ha-en	Online-B	1356	False	chrf-A	0.466582
8	ha-en	Facebook-AI	181	False	bleu-all	20.982704
9	ha-en	Facebook-AI	181	False	chrf-all	0.486538
10	ha-en	Facebook-AI	181	False	bleu-A	20.982704
11	ha-en	Facebook-AI	181	False	chrf-A	0.486538
12	ha-en	Manifold	437	True	bleu-all	16.943915
13	ha-en	Manifold	437	True	chrf-all	0.456384
14	ha-en	Manifold	437	True	bleu-A	16.943915
15						
	ha-en	Manifold	437	True	chrf-A	0.456384
16	ha-en	Online-Y	1374	False	bleu-all	13.898531
17	ha-en	Online-Y	1374	False	chrf-all	0.448429
18	ha-en	Online-Y	1374	False	bleu-A	13.898531
19	ha-en	Online-Y	1374	False	chrf-A	0.448429
20	ha-en	TWB	1335	False	bleu-all	12.326443
21			1335	False	chrf-all	0.402826
	ha-en	TWB				
22	ha-en	TWB	1335	False	bleu-A	12.326443
23	ha-en	TWB	1335	False	chrf-A	0.402826
24	ha-en	MS-EgDC	896	True	bleu-all	17.133350
25	ha-en	MS-EgDC	896	True	chrf-all	0.452663
26	ha-en	MS-EgDC	896	True	bleu-A	17.133350
27	ha-en	•	896	True	chrf-A	0.452663
		MS-EgDC				
28	ha-en	TRANSSION	336	False	bleu-all	18.834851
29	ha-en	TRANSSION	336	False	chrf-all	0.472383
30	ha-en	TRANSSION	336	False	bleu-A	18.834851
31	ha-en	TRANSSION	336	False	chrf-A	0.472383
32	ha-en	AMU	628	True	bleu-all	14.132845
33	ha-en	AMU	628	True	chrf-all	0.412566
34	ha-en	AMU	628	True	bleu-A	14.132845
35	ha-en	AMU	628	True	chrf-A	0.412566
36	ha-en	UEdin	1149	True	bleu-all	14.887836
37	ha-en	UEdin	1149	True	chrf-all	0.422474
38	ha-en	UEdin	1149	True	bleu-A	14.887836
39	ha-en	UEdin	1149	True	chrf-A	0.422474
40	ha-en	ZMT	553	False	bleu-all	18.837023
41	ha-en	ZMT	553	False	chrf-all	0.472315
42	ha-en	ZMT	553	False	bleu-A	18.837023
43	ha-en	ZMT	553	False	chrf-A	0.472315
44	ha-en	P3AI	715	True	bleu-all	17.793617
45	ha-en	P3AI	715	True	chrf-all	0.463074
46	ha-en	P3AI	715	True	bleu-A	17.793617
47	ha-en	P3AI	715	True	chrf-A	0.463074
48	ha-en	HuaweiTSC	758	True	bleu-all	17.492440
49	ha-en	HuaweiTSC	758	True	chrf-all	0.467957
50	ha-en	HuaweiTSC	758	True	bleu-A	17.492440
51	ha-en	HuaweiTSC	758	True	chrf-A	0.467957
52	ha-en	GTCOM	1298	False	bleu-all	17.794272
02	110 CII	GIOUN	1200	1 0156	DICG GII	11.107212

```
53
        ha-en
                      GTCOM
                              1298
                                              False
                                                     chrf-all
                                                                 0.467148
     54 ha-en
                       GTCOM
                              1298
                                              False
                                                               17.794272
                                                       bleu-A
     55
        ha-en
                       GTCOM
                              1298
                                              False
                                                       chrf-A
                                                                 0.467148
[]: df[df.pair == 'ha-en'].pivot(index='system', columns='metric', values='score')
                     bleu-A
                               bleu-all
                                            chrf-A chrf-all
[]: metric
     system
     AMU
                  14.132845
                              14.132845
                                         0.412566
                                                    0.412566
     Facebook-AI
                  20.982704
                              20.982704
                                         0.486538
                                                    0.486538
     GTCOM
                  17.794272
                              17.794272
                                         0.467148
                                                    0.467148
     HuaweiTSC
                  17.492440
                              17.492440
                                         0.467957
                                                    0.467957
     MS-EgDC
                  17.133350
                              17.133350
                                         0.452663
                                                    0.452663
     Manifold
                                         0.456384
                  16.943915
                              16.943915
                                                    0.456384
     NiuTrans
                  16.512243
                              16.512243
                                         0.447248
                                                    0.447248
     Online-B
                  18.655658
                              18.655658
                                         0.466582
                                                    0.466582
     Online-Y
                                                    0.448429
                  13.898531
                              13.898531
                                         0.448429
     P3AI
                  17.793617
                              17.793617
                                         0.463074
                                                    0.463074
                                                    0.472383
     TRANSSION
                  18.834851
                              18.834851
                                         0.472383
     TWB
                  12.326443
                              12.326443
                                         0.402826
                                                    0.402826
     UEdin
                  14.887836
                              14.887836
                                         0.422474
                                                    0.422474
     ZMT
                  18.837023
                              18.837023
                                         0.472315
                                                    0.472315
    Dane tekstowe pandas posiada udogodnienia do pracy z wartościami tekstowymi: * dostęp
    następuje przez atrybut str; * funkcje: * formatujące: lower(), upper(); * wyrażenia regularne:
    contains(), match(); * inne: split()
[]:|df = pd.read_csv('./titanic_train.tsv', sep='\t', index_col='PassengerId')
     df.head()
[]:
                  Survived Pclass
    PassengerId
                          0
     1
                                  3
     2
                          1
                                  1
     3
                          1
                                  3
     4
                          1
                                  1
     5
                          0
                                  3
                                                                 Name
                                                                           Sex
                                                                                 Age \
     PassengerId
                                            Braund\t Mr. Owen Harris
                                                                          male
     1
                                                                                22.0
     2
                  Cumings\t Mrs. John Bradley (Florence Briggs T... female
                                                                              38.0
     3
                                              Heikkinen\t Miss. Laina
                                                                        female
                                                                                26.0
     4
                      Futrelle\t Mrs. Jacques Heath (Lily May Peel)
                                                                        female
                                                                                35.0
     5
                                            Allen\t Mr. William Henry
                                                                                35.0
                                                                          male
```

```
PassengerId
     1
                      1
                              0
                                        A/5 21171
                                                     7.2500
                                                              NaN
                                                                          S
     2
                                         PC 17599
                                                    71.2833
                                                                          С
                      1
                              0
                                                              C85
     3
                      0
                              0
                                 STON/02. 3101282
                                                    7.9250
                                                              NaN
                                                                          S
                                                                          S
     4
                      1
                              0
                                           113803 53.1000
                                                             C123
     5
                      0
                              0
                                           373450
                                                     8.0500
                                                              NaN
                                                                          S
[]: df.Name.str.upper()
[]: PassengerId
     1
                                      BRAUND\t MR. OWEN HARRIS
     2
            CUMINGS\t MRS. JOHN BRADLEY (FLORENCE BRIGGS T ...
     3
                                       HEIKKINEN\t MISS. LAINA
     4
                FUTRELLE\t MRS. JACQUES HEATH (LILY MAY PEEL)
                                     ALLEN\t MR. WILLIAM HENRY
     5
     887
                                        MONTVILA\t REV. JUOZAS
                                 GRAHAM\t MISS. MARGARET EDITH
     888
     889
                    JOHNSTON\t MISS. CATHERINE HELEN "CARRIE"
     890
                                        BEHR\t MR. KARL HOWELL
     891
                                          DOOLEY\t MR. PATRICK
     Name: Name, Length: 891, dtype: object
[]: print(df.Name.head())
     df.Name.str.contains('Miss|Mrs').head()
    PassengerId
    1
                                   Braund\t Mr. Owen Harris
    2
         Cumings\t Mrs. John Bradley (Florence Briggs T...
    3
                                    Heikkinen\t Miss. Laina
    4
             Futrelle\t Mrs. Jacques Heath (Lily May Peel)
                                  Allen\t Mr. William Henry
    Name: Name, dtype: object
[]: PassengerId
          False
     1
     2
           True
     3
           True
     4
           True
          False
     Name: Name, dtype: bool
[]: df.Name.str.split('\t', expand=True)
[]:
                           0
                                                                          1
     PassengerId
```

Ticket

Fare Cabin Embarked

SibSp Parch

```
2
                              Mrs. John Bradley (Florence Briggs Thayer)
                    Cumings
     3
                  Heikkinen
                                                              Miss. Laina
     4
                   Futrelle
                                       Mrs. Jacques Heath (Lily May Peel)
     5
                      Allen
                                                        Mr. William Henry
                                                              Rev. Juozas
    887
                   Montvila
    888
                     Graham
                                                     Miss. Margaret Edith
                                          Miss. Catherine Helen "Carrie"
    889
                   Johnston
                                                          Mr. Karl Howell
     890
                       Behr
                                                              Mr. Patrick
     891
                     Dooley
     [891 rows x 2 columns]
[]: df.Name.str.split('\t')
[]: PassengerId
                                    [Braund, Mr. Owen Harris]
     2
            [Cumings, Mrs. John Bradley (Florence Briggs ...
     3
                                     [Heikkinen, Miss. Laina]
     4
              [Futrelle, Mrs. Jacques Heath (Lily May Peel)]
     5
                                   [Allen, Mr. William Henry]
    887
                                      [Montvila, Rev. Juozas]
    888
                               [Graham,
                                        Miss. Margaret Edith]
    889
                              Miss. Catherine Helen "Carrie"]
     890
                                      [Behr, Mr. Karl Howell]
     891
                                        [Dooley, Mr. Patrick]
    Name: Name, Length: 891, dtype: object
[]: df.Name.str.split('\t').str[1]
[]: PassengerId
                                         Mr. Owen Harris
     2
             Mrs. John Bradley (Florence Briggs Thayer)
     3
                                             Miss. Laina
     4
                     Mrs. Jacques Heath (Lily May Peel)
     5
                                       Mr. William Henry
    887
                                             Rev. Juozas
    888
                                    Miss. Margaret Edith
                         Miss. Catherine Helen "Carrie"
    889
    890
                                         Mr. Karl Howell
    891
                                             Mr. Patrick
    Name: Name, Length: 891, dtype: object
[]: df.Name.str.split('\t').str[1].str.strip().str.split(' ').str[0]
```

Mr. Owen Harris

1

Braund

```
[]: PassengerId
     1
               {\tt Mr.}
     2
              Mrs.
     3
             {\tt Miss.}
     4
              Mrs.
     5
               Mr.
     887
             Rev.
             Miss.
     888
     889
             Miss.
     890
               Mr.
     891
               Mr.
     Name: Name, Length: 891, dtype: object
```